

# Analiza statystyczna i prognozowanie ruchu pasażerskiego w Polsce w obliczu szoku pandemicznego

Zuzanna Nogala, Joanna Pokora


## Spis treści

|          |                                                                |           |
|----------|----------------------------------------------------------------|-----------|
| <b>1</b> | <b>Wstęp</b>                                                   | <b>2</b>  |
| <b>2</b> | <b>Analiza danych</b>                                          | <b>3</b>  |
| 2.1      | Dekompozycja szeregu . . . . .                                 | 3         |
| 2.2      | Analiza trendu przed i po okresie pandemicznym . . . . .       | 5         |
| 2.3      | Analiza sezonowości przed i po okresie pandemicznym . . . . .  | 7         |
| <b>3</b> | <b>Jakie problemy (scenariusze) rozważamy?</b>                 | <b>8</b>  |
| <b>4</b> | <b>Rozważane modele</b>                                        | <b>9</b>  |
| 4.1      | Model SARIMA . . . . .                                         | 9         |
| 4.2      | Model Prophet . . . . .                                        | 10        |
| <b>5</b> | <b>Kryteria oceny modeli</b>                                   | <b>11</b> |
| <b>6</b> | <b>Modelowanie danych</b>                                      | <b>11</b> |
| 6.1      | Scenariusz 1: modelowanie danych z ignorowaniem COVIDU . . .   | 11        |
| 6.1.1    | SARIMA . . . . .                                               | 12        |
| 6.1.2    | Prophet . . . . .                                              | 15        |
| 6.1.3    | Wnioski . . . . .                                              | 15        |
| 6.2      | Scenariusz 2: modelowanie danych z uwzględnieniem covidu . . . | 18        |
| 6.2.1    | SARIMA . . . . .                                               | 18        |
| 6.2.2    | Prophet . . . . .                                              | 21        |
| 6.2.3    | Wnioski . . . . .                                              | 22        |
| 6.3      | Scenariusz 3: imputacja covidu . . . . .                       | 24        |
| 6.3.1    | SARIMA . . . . .                                               | 25        |
| 6.3.2    | Prophet . . . . .                                              | 29        |
| 6.3.3    | Wnioski . . . . .                                              | 29        |
| <b>7</b> | <b>Wybór najlepszego modelu oraz prognozy na przyszłość</b>    | <b>31</b> |
| <b>8</b> | <b>Podsumowanie</b>                                            | <b>32</b> |

# 1 Wstęp

W projekcie przeprowadzimy analizę liczby pasażerów, którzy skorzystali z transportu lotniczego w Polsce na przestrzeni 21 lat. Dokładniej, analiza obejmuje lata 2004-2025, co pozwala na prześledzenie pełnej ewolucji polskiego rynku lotniczego: od momentu wejścia Polski do Unii Europejskiej, przez okres dynamicznego wzrostu, aż po drastyczne załamanie się spowodowane epidemią COVID-19 i fazę odbudowy.

Analiza została przeprowadzona na danych w ujęciu miesięcznym z bazy Eurostat (identyfikator: [avia\\_paoc](#)), która zawiera statystyki dotyczące pasażerów obsługiwanych we wszystkich krajach członkowskich Unii Europejskiej, w tym w Polsce. Dane te uwzględniają zarówno ruch krajowy, jak i międzynarodowy (wewnątrz i poza UE). Statystyki dla Polski przedstawione zostały na rysunku 1.



Rysunek 1: Liczba pasażerów obsługiwanych przez transport lotniczy w Polsce

W projekcie skupimy się na wpływie pandemii COVID-19 na liczbę pasażerów w Polsce. Zbadamy, jak okres załamania rynku wpłynął na strukturę trendu oraz sezonowość danych. Ponadto przeanalizujemy różne scenariusze uwzględniania okresu pandemicznego:

- pominięcie wpływu kryzysu (podejście naiwne),
- modelowanie załamania rynku,
- uzupełnianie danych metodą imputacji.

Takie podejście pozwoli nam ocenić, jak powyższe strategie przygotowania szeregu czasowego wpływają na zdolność modeli SARIMA i Prophet do odwzorowania faktycznej dynamiki danych w okresie po załamaniu rynku. Na koniec wybierzemy najlepszą strategię i odpowiadający jej model, by na jego podstawie prognozować kondycję polskich linii lotniczych w perspektywie najbliższych 5 lat.

## 2 Analiza danych

Wybuch pandemii drastycznie wpłynął na dynamikę danych, dlatego analizowany zbiór został podzielony na trzy kluczowe etapy, wyszczególnione w poniższej tabeli.

Tabela 1: Podział ram czasowych analizy ruchu pasażerskiego w Polsce

| Nazwa okresu       | Start      | Koniec     | Charakterystyka etapu                                                    |
|--------------------|------------|------------|--------------------------------------------------------------------------|
| Przed pandemią     | 01.01.2004 | 01.02.2020 | Rozwój linii lotniczych.                                                 |
| W trakcie pandemii | 01.03.2020 | 01.05.2022 | Restrykcje sanitarne, lockdowny i drastyczny spadek operacji lotniczych. |
| Po pandemii        | 01.06.2022 | 01.08.2025 | Faza odbudowy popytu na rynku lotniczym.                                 |

Rysunek 2 obrazuje wygląd poszczególnych okresów w kontekście liczby przewozów lotniczych.



Rysunek 2: Podział danych na okresy przed epidemią, w trakcie oraz po epidemii

W dalszej części rozdziału skupimy się na analizie tych okresów pod kątem teorii szeregów czasowych, aby wyraźnie zobrazować, jak zmieniła się charakterystyka rynku przed pandemią i po jej zakończeniu.

### 2.1 Dekompozycja szeregu

Wprowadźmy oznaczenia na komponenty szeregu czasowego  $Y_t$ . Zdefiniujmy:


- Dane ( $Y_t$ ): Dane wejściowe, czyli analizowany szereg czasowy.
- Trend ( $T_t$ ): Długookresowy kierunek zmian.

- Sezonowość ( $S_t$ ): Powtarzalne wahania roczne.
- Reszty/Błąd ( $E_t$ ): Szum w danych.

Ze względu na zmieniającą się sezonowość i zwiększającą się wariancję danych w czasie, do dekompozycji szeregu zastosujemy model multiplikatywny, który jest postaci:

$$Y_t = T_t \cdot S_t \cdot E_t.$$

Wykres poniżej przedstawia nasz analizowany szereg czasowy i poszczególne komponenty, uzyskane przy pomocy średniej ruchomej.



Rysunek 3: Dekompozycja szeregu czasowego

Komponenta sezonowa wyznaczona została jako średnia dla każdego miesiąca po wszystkich latach. Z tego powodu na rysunku 3 ma ona tę samą postać w każdym roku, a dokładna analiza sezonowości przeprowadzona zostanie osobno, w podrozdziale 2.3.

W okresie przed epidemią (lata 2004-2019), liczba pasażerów charakteryzuje się w ogólności trendem rosnącym. Niewielkie zaburzenie monotoniczności występuje szczególnie w latach 2008 i 2009, czyli w okresie globalnego kryzysu finansowego. W 2020 r., z powodu epidemii oraz związanych z nią obostrzeń, nastąpiło drastyczne załamanie się trendu. Ponownie zaczął być on rosnący dopiero około rok później. Warto zatem dokładniej przeanalizować trend w okresach przed i po pandemii COVID-19, aby zweryfikować wpływ kryzysu na badany szereg czasowy.

Wartości reszt z przeprowadzonej dekompozycji charakteryzują się dużymi odchyleniami w okolicach okresu epidemii. Oznacza to, że uzyskane komponenty nie oddają w pełni zaburzeń pojawiających się w tych latach. W pozostałych

przypadkach reszty są bliskie 1, co oznacza, że iloczyn  $T_s \cdot S_t$  dość dobrze przybliża rzeczywiste wartości. Reszty nie są jednak w pełni losowe, ponieważ można w nich dostrzec strukturę związaną z sezonowością.

## 2.2 Analiza trendu przed i po okresie pandemicznym

Jak wspomniano w podrozdziale 2.1, przed wybuchem pandemii w danych był widoczny rosnący trend. Do około 2017 roku jego przebieg był zbliżony do liniowego. Natomiast w kolejnych latach nastąpiło wyraźnie przyspieszenie wzrostu, a obserwowana tendencja zaczęła przyjmować formę wykładniczą. Ta zmiana dynamiki wzrostu skłoniła nas do wyboru modelu wykładniczego do dalszej analizy danych.

Modelowanie trendu zrealizowano dla trzech kluczowych faz:


1. przedpandemicznej (01-01-2004 - 01-02-2020),
2. uwzględniającej epidemię (01-01-2004 - 01-05-2022),
3. pospandemicznej, okresu odbudowy (01-05-2022 - 01-08-2025).

Parametry trendu wykładniczego zostaną oszacowane przy użyciu modelu regresji log-liniowej o następującej postaci:


$$\log(Y_t) = \beta_0 + \beta_1 t + \epsilon_t$$

- $\beta_0, \beta_1$  to współczynniki regresji,
- $t$  - zmienna czasowa,
- $\epsilon$  - składnik losowy (szum).

Dopasowane trendy wraz z predykcjami na przyszłość są przedstawiane na wykresach poniżej.



Rysunek 4: Analiza trendu



Rysunek 5: Analiza trendu

Najbardziej uderzającym wnioskiem z analizy wykresów jest dystans między linią czerwoną (scenariusz „gdyby nie było epidemii”) a niebieską (nowa rzeczywistość). Branża lotnicza w Polsce nie wróciła na dawną ścieżkę wzrostu, lecz weszła na nową, równoległą, ale przesuniętą w dół. Oznacza, to że pandemia cofnęła rozwój rynku o kilka lat.


Natomiast trend uwzględniający epidemię (zielony) jest bardzo płaski i prowadzi do dużego niedoszacowania. Operowanie na estymacjach trendu z uwzględnieniem pandemii doprowadziłoby do niedoinwestowania infrastruktury i utraty

udziałów w rynku na rzecz bardziej agresywnej konkurencji, która dostrzegła „odbicie” (trend niebieski).

Mimo że trend w fazie odbudowy startuje z niższego poziomu niż czerwona krzywa, jej nachylenie sugeruje silną dynamikę. Oznacza, to że potrzeba latania Polaków nie zmieniła się trwale pod wpływem pandemii. Zatem pomimo gwałtownego załamania rynku, okazał się on odporny na zmianę nawyków konsumentów i wykazuje stabilną strukturę wzrostu.


### 2.3 Analiza sezonowości przed i po okresie pandemicznym

Przeanalizujemy sezonowość w oparciu o rozkład liczby pasażerów w poszczególnych miesiącach przed pandemią i w fazie regeneracji rynku, po epidemii. Zbadamy, w jaki sposób pandemia wpłynęła na zmianę sezonowości.



Rysunek 6: Analiza sezonowości

Z uwagi na fakt, że 16-letni okres przedpandemiczny zawiera dane historyczne, które są mało reprezentatywne dla lat bezpośrednio poprzedzających pandemię, zestawimy rozkład liczby pasażerów w ujęciu miesięcznym z ostatnich 3 lat przed jej rozpoczęciem (2017 - 2020) oraz z 3 lat po jej rozpoczęciu (2022 - 2025).



Rysunek 7: Analiza sezonowości

Analizując wykres, można zauważyć, że zarówno przed i po pandemii rynek lotniczy osiąga swój szczyt w okresie wakacyjnym. Natomiast w fazie odbudowy rynku, w szczycie sezonu (lipiec i sierpień) mediana pasażerów jest większa o blisko milion pasażerów. Oznacza to, że infrastruktura lotniska musi mierzyć się z znacznie większym obciążeniem niż przed rokiem 2020.

Istotną różnicą pomiędzy okresami jest fakt, że po pandemii do miesięcy szczytowych dołączyły maj, czerwiec i wrzesień. Sugeruje to, że sezon zarobkowy dla linii lotniczych wydłużył się.

Mimo ogólnego wzrostu rynku, sezon zimowy (listopad – luty) pozostaje najmniej dochodowym okresem w roku. Natomiast w tych miesiącach rozkład jest bardziej stabilny, a zakresy zmienności (wysokość pudełek) są zbliżone do tych sprzed pandemii, pomimo większej liczby pasażerów.

Podsumowując: choć sezonowość zachowała swój klasyczny kształt (letni szczyt i zimowy dołek), to amplituda między sezonami drastycznie wzrosła. Rynek stał się większy, ale jednocześnie trudniejszy do prognozowania w krótkim terminie.

### 3 Jakie problemy (scenariusze) rozważamy?

Załamanie trendu w okresie pandemii COVID-19 oraz gwałtowny wzrost liczby pasażerów w późniejszym czasie sprawiają, że wytrenowanie modelu na oryginalnych danych może nie zapewnić dobrego dopasowania ani trafnych prognoz. Aby się o tym przekonać i porównać różne strategie, przeanalizujemy następujące przypadki.



1. Co by było, gdyby zignorować okres COVID-19 w modelowaniu?
2. Co by było, gdyby uwzględnić oryginalne dane z okresu pandemii w modelowaniu?
3. Co by było, gdyby zaimputować dane z okresu pandemii na podstawie poprzednich lat?

## 4 Rozważane modele

Do modelowania danych posłużymy się klasycznym modelem statystycznym do prognozowania szeregów czasowych **SARIMA** oraz opracowanym przez firmę Meta narzędziem **Prophet**, które świetnie radzi sobie z analizą szeregów czasowych wykazujących silną sezonowość.

### 4.1 Model SARIMA

Niech  $X_t$  będzie dowolnym szeregiem czasowym. Operator przesunięcia definiujemy jako

$$LX_t = X_{t-1}.$$

Wtedy operator różnicowania krokiem  $d$  zadany jest wzorem

$$\nabla_d X_t = (I - L^d) X_t = X_t - X_{t-d}.$$

Stacjonarny szereg  $X_t$  nazywamy sezonowym szeregiem typu  $\text{SARIMA}(p, d, q) \times (P, D, Q)_s$  z okresem  $s$  oraz rzędami  $d \geq 0$ ,  $D \geq 0$ , gdy spełnia on równanie

$$\phi(L)\Phi(L^s)\nabla^d(1 - L^s)^D X_t = \theta(L)\Theta(L^s)W_t,$$

gdzie  $W_t \sim \text{WN}(0, \sigma^2)$  oraz

$$\begin{aligned} \phi(z) &= 1 - \phi_1 z - \dots - \phi_p z^p & \theta(z) &= 1 + \theta_1 z + \dots + \theta_q z^q \\ \Phi(z) &= 1 - \Phi_1 z - \dots - \Phi_P z^P & \Theta(z) &= 1 + \Theta_1 z + \dots + \Theta_Q z^Q. \end{aligned}$$

Aby dopasować dane do modelu SARIMA w R, używamy funkcji `auto.arima()` z pakietu `forecast` oraz funkcji `arima()` z biblioteki `stats`. W pierwszym przypadku, parametry dobierane są automatycznie poprzez porównanie wartości kryterium  $AIC$  dla różnych modeli. Wykorzystane zostaną dwie konfiguracje ustawień:

- domyślne, tzn. `max.p=max.q=5` oraz `max.P=max.Q=2`,
- `max.p=max.q=8` bez estymacji krokowej (`stepwise=FALSE`; porównywana jest większa liczba modeli) oraz z sumą  $p + q + P + Q$  równą maksymalnie 8.

Druga funkcja wymaga podania z góry parametrów, które dobrane zostaną na podstawie wykresów funkcji autokorelacji oraz autokowariancji.

W kontekście naszych danych, łatwo zauważyć, że analizowany szereg czasowy nie spełnia wymogu stacjonarności. Zarówno średnia, jak i wariancja zmieniają się w czasie ze względu na trend wzrostowy oraz silne wahania sezonowe. Dlatego przed dopasowaniem modelu SARIMA zastosujemy transformację logarytmiczną, aby ustabilizować wariancję. Następnie, w celu uzyskania postaci bliskiej stacjonarności, usuniemy sezonowość różnicowaniem z krokiem 12 oraz wyeliminujemy trend za pomocą kolejnego różnicowania (przyjmujemy więc wartości parametrów różnicowania  $d = 1$  oraz  $D = 1$ ).

## 4.2 Model Prophet

Model Prophet to narzędzie opracowane przez firmę Meta, zaprojektowane do prognozowania szeregów czasowych, które często charakteryzują się silną sezonowością, wpływem świąt oraz zmianami trendów. Podstawowa postać modelu opiera się na strukturze addytywnej :

$$Y_t = T_t + S_t + H_t + E_t,$$

gdzie

- $T_t$  - trend, który może być modelowany jako funkcja liniowa, logistyczna lub stała.
- $S_t$  - sezonowość, reprezentowana za pomocą szeregu Fouriera.
- $H_t$  - efekty "świąt": wpływ specyficznych dni, które mogą zaburzać regularny rytm danych.
- $E_t$  - błąd / składnik losowy (szum) z rozkładu normalnego  $\mathcal{N}(0, \sigma^2)$ .

Prophet umożliwia również zastosowanie modelu multiplikatywnego, który jest szczególnie przydatny, gdy amplituda wahań sezonowych rośnie wraz z trendem, tak jak w przypadku naszych danych. Użyjemy go zatem w dalszych symulacjach. Jego postać definiuje się jako:

$$Y_t = T_t \cdot (1 + S_t + H_t) + E_t.$$

Największą zaletą modelu jest brak wymogu stacjonarności szeregu. Dlatego w tym przypadku nie będziemy przekształcać danych za pomocą transformacji logarytmicznej, lecz będziemy pracować na oryginalnej skali. Narzędzie oferuje również możliwość modelowania wpływu świąt, która idealnie sprawdzi się do uwzględnienia wpływu pandemii na analizowany szereg.

Aby dopasować dane do modelu Prophet w środowisku R, używamy funkcji `prophet()` z pakietu o tej samej nazwie. Najważniejszymi parametrami modelu są:

- `growth`, `changepoints`, które odpowiadają za dopasowanie trendu. Argument `growth` wskazuje na postać funkcji trendu, natomiast `changepoints` pozwala na zdefiniowanie okresów, gdzie nastąpiło istotne załamanie trendu.
- `yearly.seasonality`, `weekly.seasonality`, `daily.seasonality` to argumenty, które określają odpowiednio roczną, tygodniową i dzienną sezonowość danych. Jeżeli jedna z powyższych sezonowości jest wykryta, reszta jest wyłączana.
- `holidays` to ramka danych z danych z okresu wakacji.
- `seasonality.mode` wskazuje na typ modelu. Automatycznie jest wybierany "additive" (addytywny), ale można również wybrać "multiplicative" (mnożkowy).

## 5 Kryteria oceny modeli

Niech  $\log L$  oznacza log-wiarogodność dopasowanego modelu,  $k$  - liczbę wyestymowanych parametrów, a  $n$  - liczbę obserwacji. Modele analizowane w rozdziale 6 ocenione zostaną przy pomocy następujących metod.

- Kryterium AIC =  $2k - 2 \log L$ .
- Kryterium BIC =  $k \log n - 2 \log L$ .
- Analizę wykresów ACF oraz PACF reszt  $r_i = y_i - \hat{y}_i$ .
- Sprawdzenie, czy model nie został przetrenowany, poprzez ocenę istotności jego współczynników.
- Pierwiastek błędu średniokwadratowego

$$\text{RMSE} = \sqrt{\frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{n}}.$$

## 6 Modelowanie danych

Na początku, szereg dzielimy na część treningową oraz testową. Przyjmujemy, że zbiór treningowy obejmuje okres od początku 2004 r. do maja 2022 r., czyli do końca ogłoszonego przez rząd stanu epidemii w Polsce. Zbiór ten będzie odpowiednio modyfikowany, w zależności od rozważanego scenariusza. Część testowa obejmuje zatem cały okres po epidemii.


### 6.1 Scenariusz 1: modelowanie danych z ignorowaniem COVIDU

W pierwszym przypadku chcemy dopasować model tylko do danych sprzed pandemii, ale jednocześnie przewidywać szereg po epidemii. Oznacza to, że w tym scenariuszu ignorujemy wpływ okresu COVID-19 na późniejsze lata.

### 6.1.1 SARIMA

Jak zauważono w rozdziale 4.1, analizowany zbiór cechuje zmieniająca się wariancja w czasie. Aby ustabilizować wahania w wartościach obserwacji i bardziej zbliżyć szereg do stacjonarnego, na dane został nałożony logarytm. Przekształcenie to będzie wykorzystywane przy każdym dopasowaniu modelu typu SARIMA.

Po zlogarytmowaniu usuwamy trend i sezonowość poprzez zróżnicowanie. Tak przekształcony szereg powinien być już zbliżony do białego szumu. Na podstawie wykresów autokorelacji (ACF) i autokorelacji cząstkowej (PACF) tak przekształconego szeregu, będziemy dopasować odpowiednie parametry komponenty sezonowej i niesezonowej.




Rysunek 8: Analiza reszt szeregu czasowego na okresie przedpandemicznym wraz wykresami ACF i PACF

Na wykresie ACF zaobserwowaliśmy istotny pik dla opóźnienia (tzn. lagu) 1. Analogicznie, w tej samej chwili wartość funkcji PACF wykracza poza 95% przedział ufności.

Dodatkowo, na wykresie ACF występuje istotna wartość w lagu 12, co sugeruje, że w komponencie sezonowej powinien być zamodelowany parametr  $Q = 1$ . Natomiast przekroczenie przedziału ufności w lagach 12, 24 i 36 w analizie PACF wskazuje na potrzebę przeanalizowania parametru AR w komponencie sezonowej. Trzy piki w tych wartościach sugerują, że parametr  $P$  może mieć wartość co najwyżej 3.

Zatem powinniśmy sprawdzić modele  $\text{SARIMA}(p, 1, q)(P, 1, Q)_{12}$ , gdzie  $p, q, Q \in \{0, 1\}$  a  $P \in \{0, 1, 2, 3\}$ .

W pierwszej kolejności przeanalizujemy modele o prostszej strukturze, by ocenić czy są one w stanie adekwatnie opisać analizowany szereg czasowy. Zaczniemy od porównania wykresów ACF i PACF dla modeli:  $\text{SARIMA}(0, 1, 1)(0, 1, 1)_{12}$ ,  $\text{SARIMA}(1, 1, 1)(0, 1, 1)_{12}$  oraz  $\text{SARIMA}(0, 1, 2)(0, 1, 1)_{12}$ .



Rysunek 9: Wykresy ACF i PACF dla wartości resztowych wybranych modeli  $\text{SARIMA}(p, 1, q)(P, 1, Q)_{12}$

Analiza wykresów ACF i PACF wskazuje, że residua wybranych modeli SARIMA nie są statystycznie istotne, co sugeruje, że wartości resztowe są białym szumem. Zatem przeanalizujemy kryteria informacyjne oraz istotność parametrów modeli.

Tabela 2: Istotność parametrów i wartości kryteriów informacyjnych dla porównywanych modeli  $\text{SARIMA}(p, 1, q)(P, 1, Q)_{12}$

| p | q | P | Q | AIC     | BIC     | Czy wszystkie parametry są istotne? | Nieistotne parametry |
|---|---|---|---|---------|---------|-------------------------------------|----------------------|
| 0 | 1 | 0 | 1 | -532.58 | -522.98 | TAK                                 | -                    |
| 1 | 1 | 1 | 1 | -531.96 | -515.97 | NIE                                 | MA(1), SAR(1)        |
| 0 | 2 | 0 | 1 | -532.34 | -519.54 | NIE                                 | MA(2)                |

Wyniki analizy wskazują, że optymalnym modelem jest  $\text{SARIMA}(0, 1, 0)(0, 1, 0)_{12}$ . Jako jedyny charakteryzuje się pełną istotnością parametrów, przy jednoczesnym zachowaniu najniższych wartości kryteriów informacyjnych AIC oraz BIC.

Ze względu na występowanie nieistotnych parametrów w innych, nadal relatywnie prostych modelach, zrezygnujemy z testowania bardziej złożonych struktur, uznając wybrany model za ostateczny.


Oprócz manualnej selekcji modelu SARIMA, zastosowano także automatyczny dobór parametrów. Rozważmy na początek otrzymane liczby parametrów, ich istotność oraz wartości kryteriów.

Tabela 3: Porównanie wyników automatycznych dopasowań modeli SARIMA na danych bez epidemii

|                    | p | q | P | Q | AIC     | BIC     | Liczba istotnych parametrów |
|--------------------|---|---|---|---|---------|---------|-----------------------------|
| <b>auto SARIMA</b> | 4 | 2 | 2 | 1 | -523.42 | -491.43 | 1                           |
| <b>max SARIMA</b>  | 4 | 0 | 2 | 2 | -525.34 | -496.55 | 0                           |

Oba modele mają wiele parametrów, z których większość jest nieistotna (wyjątkiem jest współczynnik SMA(1) w modelu „auto SARIMA”). Wskazuje to na przetrenowanie wynikające ze zbyt dużej złożoności. Wartości AIC i BIC dla obu modeli są zbliżone, jednak nieco lepszy jest model SARIMA z ręcznie zmodyfikowanymi maksymalnymi wartościami parametrów, wyznaczony bez przeszukiwania *stepwise*.

Przyjrzyjmy się teraz wykresom ACF i PACF otrzymanych reszt.



Rysunek 10: Wykresy ACF i PACF dla reszt modeli SARIMA( $p, 1, q$ )( $P, 1, Q$ )<sub>12</sub> dopasowanych automatycznie do danych bez epidemii.


Powyższe wykresy są podobne do tych na rysunku 9, dla modeli SARIMA wyznaczonych ręcznie. Oznacza to, że dodanie parametrów nie zmieniło za bardzo struktury modeli. Większe sygnały pojawiają się w lagu 6 oraz 21, pozostają

one natomiast w granicach nieistotności lub tylko trochę ją przekraczają. Można zatem przyjąć, że reszty są szumem.

Porównanie modeli wybranych automatycznie z modelem eksperckim zostanie opisane w sekcji 6.1.3.

### 6.1.2 Prophet

Jak wspomniano w rozdziale 4.2, model Prophet został dopasowany na oryginalnych danych bez transformacji logarytmicznej, przy założeniu trendu moltiplicatywnego. Ponieważ okres epidemii COVID-19 nie został uwzględniony w zbiorze treningowym, to model wyznacza nowe prognozy na podstawie wcześniejszego, stabilnie rosnącego trendu. Prognozy na wykresie 11 są więc naturalnie dalekie od rzeczywistych wartości w zbiorze testowym.




Rysunek 11: Porównanie zbiorów treningowych i testowych z predykcjami modelu Prophet.

### 6.1.3 Wnioski

W tabeli 4 przedstawiono zestawienie wartości RMSE dla modeli omówionych w Scenariuszu 1. Na wykresie 13 przedstawiono natomiast ich dopasowanie i prognozy.


Tabela 4: Porównanie ilorazów RMSE względem najlepszego modelu na zbiorze testowym dla Scenariusza 1

| Model                       | RMSE na okresie |                    |                  |
|-----------------------------|-----------------|--------------------|------------------|
|                             | przed pandemią  | w trakcie epidemii | po pandemii      |
| Prophet                     | 85 747,96       | <b>3 368 389</b>   | <b>1 421 368</b> |
| SARIMA (automatyczna)       | 87,36%          | 101,65%            | 147,78%          |
| SARIMA (automatyczna z max) | 87,41%          | 101,83%            | 151,22%          |
| SARIMA (ekspercka)          | <b>86,71%</b>   | 103,14%            | 160,33%          |



Rysunek 12: Podsumowanie dopasowania i prognoz modeli w Scenariuszu 1 (na całym zbiorze)





Rysunek 13: Podsumowanie dopasowania i prognoz modeli w Scenariuszu 1 (na zbiorze testowym)

Mimo że model SARIMA wyłoniony manualnie charakteryzował się najlepszymi statystykami dopasowania na zbiorze treningowym (niższe wartości AIC/BIC i wysoka istotność współczynników), jego trafność po 2020 roku była niższa niż w przypadku modeli SARIMA automatycznych i wystąpił overfitting.

Automatyczne modele SARIMA, pomimo istotnie większej liczby parametrów, poradziły sobie z dopasowaniem jedynie nieznacznie lepiej niż najlepsza SARIMA ekspercka. Pod względem trafności prognoz poza próbą, najkorzystniej zaprezentował się model Prophet.

Natomiast należy zaznaczyć, że każdy model trenowany na danych sprzed 2020 roku nie uwzględnia szoku strukturalnego, przez co ich trafność w kolejnych latach jest niska i znacząco przeszacowuje liczbę pasażerów.


Z biznesowego punktu, podążanie za modelem opartym na Scenariuszu 1 może prowadzić do błędnych decyzji inwestycyjnych i potencjalnie dużych strat. Firmy transportowe, które nie poprawiły swoich modeli mogły borykać się z ogromną nadpodażą. W okresach wysokiej zmienności biznes powinien stawiać na modele bardziej odporne, które szybciej adaptują się do nowych danych, nawet kosztem ich matematycznej „elegancji”. SARIMA wybrana ekspercko zbyt mocno trzymała się reguł wypracowanych w stabilnych czasach, co w nowej rzeczywistości stało się jej wadą.

## 6.2 Scenariusz 2: modelowanie danych z uwzględnieniem covidu

W tym scenariuszu chcemy odpowiedzieć na pytanie, jak okres drastycznego spadku liczby pasażerów w trakcie epidemii wpływa na dopasowania modeli oraz przewidywanie dalszych wartości.

### 6.2.1 SARIMA

Podobnie jak w poprzedniej sekcji, w pierwszej kolejności na podstawie wykresów ACF i PACF przeanalizujemy zlogarytmowane dane po usunięciu trendu i sezonowości.



Rysunek 14: Analiza reszt szeregu czasowego na okresie uwzględniającym pandemię wraz wykresami ACF i PACF

Na wykresie autokorelacji (ACF) zaobserwowaliśmy istotne piki dla lagów 1, 2 oraz 3. Analogiczne, w tych samych chwilach wartości funkcji autokorelacji częściowej (PACF) wykraczają poza 95% przedział ufności. Wobec tego będziemy dopasowywać model SARIMA z komponentą niesezonową postaci  $(p, 1, q)$ , gdzie  $p, q \in \{1, 2, 3\}$ .

Dodatkowo, na wykresie ACF występuje istotna wartość w lagu 12, który sugeruje, że w komponencie sezonowej powinien być zamodelowany parametr  $Q = 1$ . Brak pików w wielokrotności 12 w analizie PACF wskazuje, że część AR w koponencie sezonowej nie jest potrzebna. Dlatego komponentę sezonową wybieramy arbitralnie trójkę  $(0, 1, 1)$ .

Ostatecznie będziemy szukać odpowiedniego modelu SARIMA typu  $\text{SARIMA}(p, 1, q)(0, 1, 1)_{12}$  dla  $p, q \in \{1, 2, 3\}$ . Jako kryteria selekcji przyjęto


minimalizację wartości AIC i BIC oraz istotność współczynników, których zestawienie prezentuje poniższa tabela.

Tabela 5: Porównanie kryteriów informacyjnych dla modeli SARIMA( $p, 1, q$ )(0, 1, 1)<sub>12</sub>

| p | q | AIC    | BIC    | Czy wszystkie parametry są istotne? |
|---|---|--------|--------|-------------------------------------|
| 1 | 3 | 143,07 | 163,10 | NIE                                 |
| 2 | 1 | 148,05 | 164,74 | TAK                                 |
| 3 | 1 | 147,37 | 167,39 | NIE                                 |
| 2 | 3 | 144,31 | 167,68 | NIE                                 |
| 2 | 2 | 148,01 | 168,04 | NIE                                 |
| 3 | 2 | 149,36 | 172,73 | NIE                                 |
| 3 | 3 | 146,28 | 172,98 | NIE                                 |
| 1 | 2 | 166,21 | 182,90 | TAK                                 |
| 1 | 1 | 184,18 | 197,53 | NIE                                 |

Legenda: Modele o najniższych wartościach:  
■ obu kryteriów (AIC i BIC) ■ kryterium AIC ■ kryterium BIC.

Na podstawie tabeli z podsumowaniem wyników testów, kryterium AIC wybrało tylko nieistotne modele, dlatego sugerujemy się jedynie pierwszą trójką z kryterium BIC. Porównanie prognoz wybranych modeli znajduje się na wykresie 15.



Rysunek 15: Porównanie dopasowanie i prognoz modeli SARIMA wybieranych manualnie (na zbiorze testowym)


Analizując wyniki kryteriów, istotność parametrów i jakość prognoz najlepszym modelem okazał się  $\text{SARIMA}(2, 1, 1)(0, 1, 1)_{12}$ . Z wybranych modeli najlepiej przewidywał dane w fazie odbudowy rynku. Dlatego ostatecznie wybieramy model  $\text{SARIMA}(2, 1, 1)(0, 1, 1)_{12}$ , który w sekcji 6.2.3 zostanie zestawiony z innymi modelami z tego scenariusza.

Parametry modelu SARIMA zostały również dobrane automatycznie przy pomocy funkcji `auto.sarima()`. Ponownie rozważamy dwa modele, uzyskane przy domyślnych oraz zmodyfikowanych ustawieniach. Poniższe wykresy oraz tabela przedstawiają podsumowania modeli wybranych przez funkcję na podstawie kryterium AIC.

Tabela 6: Porównanie wyników automatycznych dopasowań modeli SARIMA na danych z epidemią

|                    | p | q | P | Q | AIC    | BIC    | Liczba istotnych parametrów |
|--------------------|---|---|---|---|--------|--------|-----------------------------|
| <b>auto SARIMA</b> | 2 | 1 | 1 | 1 | 150.04 | 170.07 | 4                           |
| <b>max SARIMA</b>  | 0 | 7 | 0 | 1 | 136.69 | 166.73 | 6                           |

Większość parametrów w uzyskanych modelach jest istotna, jednak nie wszystkie (nieistotne są: SAR(1) w modelu „auto SARIMA” oraz MA(5) i MA(6) w modelu „max SARIMA”). Ponownie, na podstawie kryteriów informacyjnych, lepszy jest model SARIMA z dostosowanymi ustawieniami.



Rysunek 16: Wykresy ACF i PACF dla reszt modeli  $\text{SARIMA}(p, 1, q)(P, 1, Q)_{12}$  dopasowanych automatycznie do danych z epidemią

Chociaż większość autokorelacji mieści się w przedziale ufności, to na wykresach pojawiają się duże piki, sugerujące pozostawanie niewyjaśnionej struktury


w resztach. Widoczne jest to szczególnie na wykresach dla „auto SARIMY”. Z kolei dla „max SARIMY” sygnały są słabsze i rzadsze, co wskazuje na lepsze dopasowanie.

Porównanie modeli wybranych automatycznie z modelem eksperckim zostanie opisane w sekcji 6.2.3.

## 6.2.2 Prophet

Jak wspomniano w rozdziale 4.2, w Prophecie nie zakładamy stacjonarności szeregu. Z tego powodu nie będziemy przekształcać analizowanych danych za pomocą logarytmowania, ale dopasujemy model na oryginalnych obserwacjach.

W pierwszej kolejności przetestowaliśmy, jak model Prophet samodzielnie dopasuje się do danych, bez podawania konkretnych wartości parametrów.




Rysunek 17: Dopasowanie i prognozy automatycznego modelu Prophet

Analiza graficzna wskazuje, że model Prophet nie odzwierciedlił poprawnie skutków szoku strukturalnego. Algorytm nie zidentyfikował dynamicznego odbicia popytu po 2021 roku i prognozy dla fazy postpandemicznej są znacząco zaniżone, sugerując zapaść rynku zamiast powrotu do trendu wzrostowego.

Teraz spróbujemy dokonać rekalkibracji modelu Prophet uwzględniając naturę szeregu i dostępną wiedzę o nim. Zoptymalizowana specyfikacja parametrów prezentuje się następująco:

- **Wydarzenia specjalne (holidays):** jako okresy o charakterze świątecznym zdefiniowano czas pandemii (01.03.2022 – 01.05.2022).
- **Punkty zmiany trendu (changepoints):** ręcznie wskazaliśmy momenty, w których nastąpiła zmiana trendu (okres pandemii).

- **Sezonowość:** w modelu uwzględniono sezonowość w cyklu rocznym.



Rysunek 18: Dopasowanie i prognozy skalibrowanego modelu Prophet


Wnioskujemy, że rekaliibracja modelu znacznie poprawiła jakość prognoz dla okresu postpandemicznego. Zoptymalizowanie parametrów pozwoliło lepiej zidentyfikować trend i dobrze oszacować liczbę pasażerów.

### 6.2.3 Wnioski


W tabeli 7 przedstawiono zestawienie wartości RMSE dla modeli omówionych w Scenariuszu 2. Natomiast na wykresie 20 przedstawiono dopasowanie i prognozy wyżej wspomnianych modeli.

Tabela 7: Porównanie ilorazów RMSE względem najlepszego modelu na zbiorze testowym dla Scenariusza 2

| Model                       | RMSE na okresie                           |                  |
|-----------------------------|-------------------------------------------|------------------|
|                             | przed pandemią<br>i w trakcie<br>epidemii | po epidemii      |
| Prophet (skalibrowany)      | 253 799,1                                 | <b>427 321,7</b> |
| SARIMA (ekspercka)          | 102,42%                                   | 210,98%          |
| SARIMA (automatyczna z max) | <b>96,32%</b>                             | 216,28%          |
| SARIMA (automatyczna)       | 102,70%                                   | 216,67%          |
| Prophet (automatyczny)      | 265,63%                                   | 564,92%          |



Rysunek 19: Porównanie dopasowania i prognoz modeli ze Scenariusza 2 (na całym zbiorze)



Rysunek 20: Porównanie dopasowania i prognoz modeli ze Scenariusza 2 (na zbiorze testowym)

Z analizy tabeli wynika, że spośród modeli SARIMA model automatyczny z ręcznie ustawionym, mniejszym ograniczeniem wielkości parametrów, jest najlepiej dopasowany do zbioru treningowego. Na zbiorze testowym natomiast najlepiej poradził sobie model wybrany ekspercko. Warto zauważyć, że w tym przypadku uwzględnienie nieistotnych statystycznie współczynników pogorszyło jakość predykcji, w przeciwieństwie do wyników otrzymanych Scenariuszu 1.

Z kolei najniższą jakość dopasowania i prognoz w obu okresach wykazał automatyczny model Prophet, który nie poradził sobie z szokiem pandemicznym. Jednak jego skalibrowana postać osiągnęła najmniejszy błąd na zbiorze testowym spośród wszystkich analizowanych modeli. Z biznesowego punktu widzenia, opieranie się na modelu z tego scenariusza przyniosło by mniejsze straty.

Wykorzystanie modeli trenowanych na danych obejmujących okres pandemii (z wyłączeniem automatycznego modelu Prophet) pozwala na podejmowanie trafniejszych decyzji inwestycyjnych i unikanie znacznych strat finansowych. Dlatego w okresach dużej zmienności biznes nie może polegać wyłącznie na automatycznych podejściach. Konieczny jest nadzór ekspercki i kalibracja modeli, aby uniknąć błędnych decyzji zakupowych czy budżetowych.

### 6.3 Scenariusz 3: imputacja covidu

W tym przypadku zastępujemy prawdziwe dane z okresu pandemii wartościami zaimputowanymi przy pomocy dekompozycji STL oraz modelu ETS.

Niech  $Y_t$  będzie oryginalnym szeregiem czasowym. Ze względu na sezonowość o zmiennej wariancji, pracować będziemy na szeregu po przekształceniu logarytmicznym. Addytywna dekompozycja STL zakłada model postaci

$$\log(Y_t) = Z_t + S_t,$$

gdzie  $S_t$  oznacza komponentę sezonową, natomiast  $Z_t$  - odsezonowany szereg.


Kolejnym krokiem jest uzyskanie predykcji w imputowanym przedziale czasowym. Wywołanie funkcji `forecast()` na obiekcie klasy `stl` dopasowuje do szeregu  $Z_t$  model  $ETS(A, Ad, N)$ , czyli zakładający addytywne błędy i addytywny trend z wygaszaniem oraz brak sezonowości. Jest to model rekurencyjny, co można zapisać w następującej postaci

$$\begin{aligned} y_t &= l_{t-1} + \phi b_{t-1} + \varepsilon_t \\ l_t &= l_{t-1} + \phi b_{t-1} + \alpha \varepsilon_t \\ b_t &= \phi b_{t-1} + \beta \varepsilon_t. \end{aligned}$$

Parametry  $\alpha$ ,  $0 < \phi < 1$  (parametr odpowiedzialny za wygaszanie trendu) oraz  $\beta$  estymowane są automatycznie przez funkcję.  $l_t$  nazwać można poziomem szeregu, a  $b_t$  składową trendu w chwili  $t$ .

Na koniec, do otrzymanych predykcji dodawana jest sezonowość z ostatniego roku przed imputowanym okresem. Poniższy wykres przedstawia pełen zbiór testowy, wraz z zaimputowanymi wartościami.






Rysunek 21: Zbiór treningowy po imputacji liczby pasażerów obsługanych w trakcie trwania epidemii

### 6.3.1 SARIMA

Analogicznie jak w poprzednich przypadkach doboru modelu SARIMA, w pierwszej kolejności przeanalizujemy zlogarytmowane dane po usunięciu trendu i sezonowości na podstawie wykresów ACF i PACF.



Rysunek 22: Analiza reszt szeregu czasowego z imputowanym okresem pandemicznym wraz wykresami ACF i PACF

Na wykresie autokorelacji i autokorelacji cząstkowej zaobserwowaliśmy tylko jeden istotny pik dla lagu 1. W związku z tym poszukiwania optymalnego mo-

delu SARIMA ograniczone zostaną do modeli o komponencie niesezonowej postaci  $(p, 1, q)$ , gdzie  $p, q \in \{0, 1\}$

Dodatkowo, na wykresie ACF występuje istotna wartość w lagu 12, który sugeruje, że w komponencie sezonowej powinien być zamodelowany parametr  $Q = 1$ . Natomiast przekroczenie przedziału ufności w lagach 12, 24 i 36 w analizie PACF wskazują na potrzebę przeanalizowania parametru AR w komponencie sezonowej. Dlatego kandydaci na komponentę sezonową będą wybierani spośród trójek postaci  $(P, 1, Q)$ , przy czym  $P \in \{1, 2, 3\}$ ,  $Q \in \{0, 1\}$

Ostateczna specyfikacja modelu  $\text{SARIMA}(p, 1, q)(P, 1, Q)_{12}$  zostanie wyłonią spośród kombinacji parametrów  $p, q \in \{0, 1\}$ ,  $P \in \{1, 2, 3\}$  oraz  $Q \in \{0, 1\}$ . Wybór optymalnego modelu zostanie dokonany w oparciu o kryteria informacyjne AIC i BIC oraz weryfikację istotności statystycznej współczynników.

Po pominięciu modelu  $\text{SARIMA}(0, 1, 0)(0, 1, 0)_{12}$ , analizie poddano 31 kombinacji parametrów, z których 12 najistotniejszych przedstawiono w tabeli 8.


Tabela 8: Porównanie kryteriów informacyjnych dla modeli  $\text{SARIMA}(p, 1, q)(P, 1, Q)_{12}$

| p | q | P | Q | AIC            | BIC            | Czy wszystkie parametry są istotne? |
|---|---|---|---|----------------|----------------|-------------------------------------|
| 1 | 0 | 0 | 1 | -642,51        | <b>-632,49</b> | TAK                                 |
| 0 | 0 | 0 | 1 | -639,14        | -632,46        | TAK                                 |
| 0 | 1 | 0 | 1 | -641,59        | -631,58        | TAK                                 |
| 1 | 1 | 0 | 1 | <b>-642,59</b> | -629,24        | TAK                                 |
| 0 | 0 | 1 | 1 | -637,65        | -627,63        | NIE                                 |
| 0 | 0 | 0 | 2 | -637,58        | -627,57        | NIE                                 |
| 1 | 0 | 1 | 1 | -640,68        | -627,33        | NIE                                 |
| 1 | 0 | 0 | 2 | -640,65        | -627,3         | NIE                                 |
| 0 | 1 | 1 | 1 | -639,8         | -626,45        | NIE                                 |
| 0 | 1 | 0 | 2 | -639,76        | -626,41        | NIE                                 |
| 1 | 1 | 1 | 1 | -640,77        | -624,08        | NIE                                 |

Legenda: Modele o najniższych wartościach:

obu kryteriów (AIC i BIC) kryterium AIC kryterium BIC.

Analiza powyższej tabeli wskazuje, że modele postaci  $\text{SARIMA}(1, 1, 0)(0, 1, 1)_{12}$ ,  $\text{SARIMA}(0, 1, 0)(0, 1, 1)_{12}$ ,  $\text{SARIMA}(0, 1, 1)(0, 1, 1)_{12}$  oraz  $\text{SARIMA}(1, 1, 1)(0, 1, 1)_{12}$  są najlepszymi kandydatami. Wszystkie te specyfikacje charakteryzują się niskimi wartościami kryteriów informacyjnych, a każdy z oszacowanych parametrów jest istotny statystycznie. Porównanie prognoz wybranych modeli na okresie postpandemicznym znajduje się na wykresie 23.



Rysunek 23: Porównanie dopasowanie i prognoz modeli SARIMA wybieranych manualnie (na zbiorze testowym)

Ze względu na brak wyraźnych różnic w wynikach analizy graficznej, ostateczny wybór modelu zostanie dokonany na podstawie porównania wartości błędu RMSE, której wartości dla poszczególnych modeli zostały umieszczone w tabeli 9.

Tabela 9: Porównanie błędów RMSE wybranych modeli SARIMA

| Model                                  | RMSE na okresie                                          |                   |
|----------------------------------------|----------------------------------------------------------|-------------------|
|                                        | przed pandemią<br>i w trakcie<br>epidemii<br>(imputacja) | po epidemii       |
| SARIMA(0, 1, 0)(0, 1, 1) <sub>12</sub> | 73 573, 39                                               | 576 352, 0        |
| SARIMA(1, 1, 0)(0, 1, 1) <sub>12</sub> | 72 649, 03                                               | 564 484, 9        |
| SARIMA(0, 1, 1)(0, 1, 1) <sub>12</sub> | 72 764, 31                                               | 568 536, 8        |
| SARIMA(1, 1, 1)(0, 1, 1) <sub>12</sub> | <b>72 521, 66</b>                                        | <b>559 787, 7</b> |


Z wartości RMSE wnioskujemy, że najlepsze dopasowanie i najmniejszy błąd prognozy ma model SARIMA(1, 1, 1)(0, 1, 1)<sub>12</sub>. W związku z tym został on wybrany jako reprezentatywny model ekspercki dla Scenariusza 3.

Przeanalizujemy teraz wyniki dla modeli dobranych automatycznie.

Tabela 10: Porównanie wyników automatycznych dopasowań modeli SARIMA na danych z zaimputowaną epidemią

|                    | p | q | P | Q | AIC     | BIC     | Liczba istotnych parametrów |
|--------------------|---|---|---|---|---------|---------|-----------------------------|
| <b>auto SARIMA</b> | 2 | 2 | 2 | 1 | -639.48 | -612.78 | 5                           |
| <b>max SARIMA</b>  | 4 | 0 | 2 | 2 | -634.95 | -604.91 | 1                           |

Pomimo podobnej liczby parametrów w obu modelach, w przypadku „max SARIMA”, istotny jest tylko jeden z nich, podczas gdy „auto SARIMA” ma aż pięć istotnych parametrów. Co więcej, inaczej niż w poprzednich scenariuszach, tym razem lepszy według kryteriów informacyjnych okazał się model dobrany całkowicie automatycznie. Pokazuje to, że nawet przy porównywaniu większej liczby modeli, dopuszczenie wyższych rzędów AR i MA oraz wybór modelu na podstawie AIC mogą prowadzić do przetrenowania.



Rysunek 24: Wykresy ACF i PACF dla wartości resztowych modeli SARIMA( $p, 1, q$ )( $P, 1, Q$ )<sub>12</sub> dopasowanych automatycznie do danych z zaimputowaną epidemią


Autokorelacje na powyższych wykresach są raczej małe. Ich struktura nieznacznie lepiej wygląda dla SARIMY automatycznej, ponieważ w drugim przypadku pojawiają się dwa duże piki, bliskie końców przedziału ufności. W ogólności można jednak przyjąć, że reszty są białym szumem.

Autokorelacje na wykresach ACF i PACF reszt są raczej małe i w większości mieszczą się w 95% przedziałach ufności. W przypadku dostosowanej ręcznie SARIMY widoczne są dwa duże piki, leżące blisko granicy istotności. W ogólności można jednak przyjąć, że reszty są białym szumem.

Porównanie modeli wybranych automatycznie z modelem eksperckim zostanie opisane w sekcji 6.3.3.

### 6.3.2 Prophet

Poniższy wykres przedstawia dopasowanie modelu Prophet do danych z zaimputowanym okresem pandemii.



Rysunek 25: Dopasowanie i prognozy automatycznego modelu Prophet


Model cechuje się dość dobrym dopasowaniem do danych. Na początku okresu odbudowy po epidemii przewidywane wartości są wyraźnie wyższe niż te rzeczywiste, natomiast dalsze predykcje są bliskie rzeczywistym wartościom ze zbioru testowego.

### 6.3.3 Wnioski


Tabela 11 zawiera zestawienie wartości RMSE dla modeli omówionych w Scenariuszu 3. Na wykresie 27 przedstawiono natomiast dopasowanie i prognozy tych modeli.

Tabela 11: Porównanie ilorazów RMSE względem najlepszego modelu na zbiorze testowym dla Scenariusza 3

| Model                       | RMSE na okresie                                          |                   |
|-----------------------------|----------------------------------------------------------|-------------------|
|                             | przed pandemią<br>i w trakcie<br>epidemii<br>(imputacja) | po epidemii       |
| SARIMA (automatyczna)       | 72 922, 24                                               | <b>548 223, 8</b> |
| SARIMA (automatyczna z max) | 99, 86%                                                  | 101, 17%          |
| SARIMA (ekspercka)          | <b>99, 45%</b>                                           | 102, 11%          |
| Prophet (automatyczny)      | 119, 81%                                                 | 102, 48%          |



Rysunek 26: Porównanie dopasowania i prognoz modeli ze Scenariusza 3 (na całym zbiorze)



Rysunek 27: Porównanie dopasowania i prognoz modeli ze Scenariusza 3 (na zbiorze testowym)

W tym przypadku, najlepszym modelem na podstawie błędu na zbiorze testowym okazała się SARIMA dopasowana w pełni automatycznie. SARIMA

ekspercka była natomiast lepiej dopasowana do zbioru treningowego, zarówno według RMSE, jak i kryteriów informacyjnych.

Model Prophet okazał się w tym przypadku nieco gorszy od pozostałych. Wszystkie wyniki są jednak bardzo zbliżone, co wskazuje, że imputacja danych uprościła analizowaną sytuację.

Z perspektywy biznesowej, stabilność wyników niezależnie od wyboru modelu można interpretować jako większą przewidywalność prognoz, a tym samym mniejsze ryzyko podejmowania decyzji. Jednocześnie należy podkreślić, że w tym przypadku kluczowe znaczenie ma sposób imputacji braków. Poprawa jakości prognoz może więc, inaczej niż w poprzednich scenariuszach, wynikać z lepszego przetworzenia danych, a nie zastosowania bardziej skomplikowanego modelu.

## 7 Wybór najlepszego modelu oraz prognozy na przyszłość

Tabela 12: Zestawienie najlepszych modeli z każdego scenariusza względem RMSE na okresie postpandemicznym

| Scenariusz             | model                  | RMSE           |
|------------------------|------------------------|----------------|
| Ignorowanie pandemii   | Prophet (automatyczny) | 1 421 368      |
| Uwzględnienie pandemii | Prophet (skalibrowany) | <b>427 322</b> |
| Imputacja pandemii     | SARIMA (automatyczna)  | 540 244        |


Na podstawie powyższej tabeli oraz obserwacji dokonanych w projekcie, najlepszym modelem okazał się skalibrowany Prophet dopasowany do danych z uwzględnieniem pandemii. Bardzo zbliżone wyniki osiągnęła jednak również automatycznie dobrana SARIMA dopasowana do zbioru z zaimitowanymi danymi. Złożoność tego modelu jest znacznie mniejsza niż w przypadku modelu Prophet, a dalsza poprawa wyników może być w tym scenariuszu stosunkowo łatwa do uzyskania dzięki dokładniejszemu doborowi metody imputacji.

Pozytywnym zaskoczeniem jest również to, że model Prophet dopasowany do oryginalnych danych tak dobrze poradził sobie z ich zamodelowaniem. W tym scenariuszu nie ma także potrzeby wprowadzania dodatkowej niepewności wynikającej z imputacji.

Najgorzej w zestawieniu wypada scenariusz z pominiętą pandemią. Niewykorzystanie dostępnych informacji stanowi w tym przypadku istotny błąd, który

skutkuje nadmiernym dopasowaniem do zbioru treningowego oraz słabą jakością dopasowania po okresie pandemii.

Ostatecznie przyjmijmy, że najlepszym modelem jest skalibrowany Prophet. Poniższy wykres jeszcze raz przedstawia uzyskane dopasowanie, wraz z prognozą na kolejne pięć lat.



Rysunek 28: Dopasowanie oraz prognozy na kolejne pięć lat na podstawie najlepszego modelu

Na podstawie uzyskanej predykcji można stwierdzić, że prognozy na kolejne lata są optymistyczne. Transport lotniczy w Polsce powinien rozwijać się stabilnie oraz obsługiwać coraz większą liczbę pasażerów. Jednocześnie należy uwzględnić większe różnice w liczbie pasażerów między sezonem letnim a pozostałą częścią roku. W praktyce oznacza to konieczność elastycznego, a jednocześnie przemyślanego planowania zasobów i kosztów.

## 8 Podsumowanie

W projekcie przeanalizowano liczbę pasażerów obsługiwanych w transporcie lotniczym w Polsce w latach 2004–2025, a więc obejmujących również okres epidemii COVID-19.

Dokładna analiza sezonowości wykazała, że po epidemii jej kształt nie uległ zmianie, natomiast zwiększyły się wariancja oraz liczba pasażerów, a także wydłużył się sezon szczytowy. Wskazuje to na pojawienie się nowych wyzwań biznesowych na rynku lotniczym w tym okresie.



Po dopasowaniu trendu przed pandemią oraz po niej okazało się, że jego kształt pozostał taki sam, co oznacza, że potrzeba latania w Polsce nie zmniejszała się. Rozwój rynku został jednak cofnięty o kilka lat.

Następnie rozważaliśmy modele SARIMA oraz Prophet przy założeniu różnych scenariuszy. Najgorszym podejściem okazało się naiwne pominięcie okresu epidemii, które nie pozwoliło uzyskać satysfakcjonujących rezultatów.

Omówiono także wyniki w przypadku dopasowania modeli do oryginalnych danych z zaimputowanym okresem epidemii. Podejścia te różnią się znacząco: w pierwszym wariancie najlepszy okazał się model bardziej złożony — skalibrowany Prophet. Z kolei imputacja uprościła analizowany szereg i umożliwiła wybór prostszego modelu SARIMA. W tym scenariuszu jakość wyników w dużej mierze zależy jednak od zastosowanej metody imputacji.

W końcu podjęliśmy próbę prognozy rozwoju rynku w ciągu kolejnych pięciu lat. Jeżeli nie wystąpią nieprzewidziane zdarzenia, liczba pasażerów powinna stale rosnąć. Rynek lotniczy musi być jednak przygotowany na wyraźne różnice między sezonem szczytowym a pozostałą częścią roku.

Uzyskane wyniki potwierdzają, że uwzględnienie zdarzeń nadzwyczajnych oraz odpowiednie przygotowanie danych mają kluczowe znaczenie dla jakości prognoz, a tym samym trafności decyzji biznesowych. Wyniki te mogą bowiem stanowić wsparcie przy zarządzaniu siatką połączeń, finansami czy infrastrukturą w warunkach rosnącego popytu oraz w obliczu nowych wyzwań.